

基于扩张重参数化和空洞卷积架构的步态识别方法

霍丽娜¹, 薛乐仁², 戴钰俊², 赵新宇², 王世行², 王 威^{1*}

(1. 河北师范大学 计算机与网络空间安全学院, 石家庄 050024; 2. 河北师范大学 软件学院, 石家庄 050024)

(* 通信作者电子邮箱 wangwei2021@hebtu.edu.cn)

摘要: 步态识别旨在通过人们的步行姿态进行身份识别。针对步态识别中有效感受野(ERF)与人体轮廓区域匹配不佳的问题, 提出一种基于空洞卷积的步态识别方法 DilatedGait。首先, 采用空洞卷积扩大神经元感受野, 缓解下采样和模型深度增加导致的分辨率下降, 以提高轮廓结构的辨识度; 其次, 提出扩张重参数化模块(DRM), 通过重参数化方法融合多尺度卷积核参数, 优化ERF聚焦范围, 使模型捕获更多的全局上下文信息; 最后, 通过特征映射提取判别性步态特征。在户外数据集 Gait3D 和 GREW 上的实验结果表明, 对比目前的先进方法 GaitBase, DilatedGait 在 Gait3D 的 Rank-1 和平均逆负惩罚(mINP)上分别提升了 9.0 和 14.2 个百分点, 在 GREW 的 Rank-1 和 Rank-5 上分别提升了 11.6 和 8.8 个百分点。可见, DilatedGait 消除了复杂协变量带来的不利影响, 能进一步提升户外场景下步态识别的准确率。

关键词: 步态识别; 有效感受野; 重参数化; 空洞卷积; 步态轮廓序列

中图分类号: TP391.4 **文献标志码:** A

Gait recognition method based on dilated reparameterization and atrous convolution architecture

HUO Lina¹, XUE Leren², DAI Yujun², ZHAO Xinyu², WANG Shihang², WANG Wei^{1*}

(1. College of Computer and Cyber Security, Hebei Normal University, Shijiazhuang Hebei 050024, China;

2. Software College, Hebei Normal University, Shijiazhuang Hebei 050024, China)

Abstract: Gait recognition aims at identifying people by their walking postures. To solve the problem of poor matching between the Effective Receptive Field (ERF) and the human silhouette region, a gait recognition method based on atrous convolution, named DilatedGait, was proposed. Firstly, atrous convolution was employed to expand the neurons' receptive fields, thereby alleviating the resolution degradation by downsampling and model deepening. Therefore, the recognizability of the silhouette structure was enhanced. Secondly, Dilated Reparameterization Module (DRM) was proposed to optimize the ERF focus range by fusing the multi-scale convolution kernel parameters through reparameterization method, thus enabling the model to capture more global contextual information. Finally, the discriminative gait features were extracted via feature mapping. Experiments were conducted on the outdoor datasets Gait3D and GREW, and the results show that compared with the existing state-of-the-art method GaitBase, DilatedGait improves 9.0 and 14.2 percentage points respectively in Rank-1 and mean Inverse Negative Penalty (mINP) on Gait3D and increases 11.6 and 8.8 percentage points respectively in Rank-1 and Rank-5 on GREW. It can be seen that DilatedGait overcomes the adverse effects of complex covariates and further enhances the accuracy of gait recognition in outdoor scenes.

Key words: gait recognition; Effective Receptive Field (ERF); reparameterization; atrous convolution; gait silhouette sequence

0 引言

步态是一种包含丰富几何信息和动态属性的生物特征, 即人在行走时特有的运动姿态和行走模式。正常行人的步态特征具有周期性、稳定性和难伪装性, 而不同个体的步态特征具有独特性和不可模仿性^[1]。于是, 基于个体步态的生

物特征识别技术被称为步态识别。步态识别基于图像和视频序列, 建模行人运动姿态, 获取目标对象最具判别性的步态特征, 以识别目标身份。相较于人脸、指纹和虹膜识别等其他技术, 步态识别具有易获取、保护隐私、远距离识别、无须目标对象配合、对图像分辨率要求低和难伪装等特点, 故该技术在刑侦调查、传染病防控和社会安全等领域具有广泛

收稿日期: 2024-05-09; 修回日期: 2024-08-29; 录用日期: 2024-09-13。

基金项目: 国家自然科学基金资助项目(61702158); 河北省教育厅重点科学基金资助项目(ZD2020317); 中央引导地方科技发展资金资助项目(236Z0102G, 226Z1808G); 河北师范大学科技类科研基金资助项目(L2024ZD15, L2024J01, L2022B22)。

作者简介: 霍丽娜(1982—), 女, 河北平山人, 副教授, 博士, 主要研究方向: 计算机视觉、多模态学习、深度学习; 薛乐仁(2002—), 男, 广东清远人, CCF 会员, 主要研究方向: 步态识别、计算机视觉、深度学习; 戴钰俊(2003—), 男, 江西九江人, 主要研究方向: 步态识别、计算机视觉、深度学习; 赵新宇(2003—), 女, 河北沧州人, 主要研究方向: 步态识别、深度学习、计算机视觉; 王世行(2004—), 男, 河南焦作人, 主要研究方向: 计算机视觉、步态识别、深度学习; 王威(1982—), 男, 河北邯郸人, 副教授, 博士, 主要研究方向: 虚拟仿真、人工智能。

的应用场景^[2]。当前,步态识别主要采用人体关键点和轮廓剪影作为步态模型的输入数据,根据不同的模态数据大致可以分为基于模型和基于外观的研究方法。

基于模型的方法通常利用人体关键点之间的联系,显式构建人体结构模型。PoseGait^[3]使用人体关节的三维坐标建立关节姿态模板,并通过卷积神经网络(Convolutional Neural Network, CNN)提取运动姿态特征。GaitGraph^[4]首创性地提出将骨骼姿态与图卷积网络(Graph Convolutional Network, GCN)结合的策略建模人体关键点信息。SMPLGait^[5]对人体网格数据进行点云化处理,建立3D人体模型提取步态特征。虽然基于模型的方法对外观变化敏感度较低,但此类方法需要较高的图像分辨率。

基于外观的方法侧重分析人体在空间中的轮廓变化,更关注整体形状和运动节奏。CSTL(Context-Sensitive Temporal feature Learning)^[6]创造性地提出了一种上下文敏感时间特征学习网络,依据上下文信息在时间维度上动态整合多层次的时间特征,实现了对多尺度时间信息的自适应融合;GaitTAKE(Gait recognition by Temporal Attention and Keypoint-guided Embedding)^[7]融合了全局与局部外观特征,并利用时间信息精炼轮廓嵌入学习,提升了特征表达的时空连贯性与辨识度;HSTL(Hierarchical Spatio-Temporal representation Learning)^[8]采用层次聚类 and 自适应区域的运动提取器分层提取步态运动特征,并进行多尺度时间下采样,减少了步态序列中的冗余信息;GaitGCI(Generative Counterfactual Intervention for Gait recognition)^[9]通过最大化事实与反事实注意力之间的似然差异,优化了对具有区分度和解释性的区域的关注,有效缓解了干扰因素的影响;GaitSet^[10]将一个人的步态序列视为无序集合并引入水平金字塔映射(Horizontal Pyramid Mapping, HPM);GaitPart^[11]采用微动作捕获模块(Micro-motion Capture Module, MCM)提取局部时间信息并将它聚合为帧间依赖性特征;GaitGL^[12]利用全局局部卷积层(Global and Local Convolution Layer)建模时空步态表征;GLN(Gait Lateral Network)^[13]通过自顶向下的方式融合不同阶段的特征,以提高多尺度健壮性。此外,最近的研究也提出了一些基于多模态的方法。GaitMix^[14]和GaitRef^[14]将骨骼和轮廓作为输入,融合轮廓和骨架特征,并进一步细化输入骨架序列中关节的位置;TransGait^[15]结合剪影与姿势热图,以构建部位级多模态特征,有效捕捉步态细节与时间动态信息。

基于外观的方法在低分辨率条件下易实施,因此可以适用于更广泛的场景。然而,当前大多数基于模型或基于外观的步态识别方法仅在受限的实验室环境下表现良好,在新提出的户外场景步态数据集上的准确率却显著降低(见2.3节)。文献[16]中指出,目前大多数具有代表性的步态识别方法在日益复杂的户外场景中表现不佳,原因可能是现实世界中存在各种在实验室场景下被消除的噪声因素,例如复杂的遮挡、背景变化和视角的任意性等。这些来自户外环境的复杂因素严重影响了深度步态模型对判别性步态特征的提取,阻碍了步态识别技术从实验室环境向户外场景的推广。因此,构建适用于户外场景的步态识别模型这一问题在学术研究和实际应用中吸引了大量的关注。

在近期的工作中,以GaitBase^[17]为首的基于类ResNet架构^[18]的CNN步态识别方法在户外步态数据集上表现出显著的性能提升。作为基于外观的方法,GaitBase同样采用轮廓剪影作为输入,并通过分析轮廓变化等信息进行识别。相关

研究^[19]表明,当图像的纹理特征(Texture Feature)存在时,CNN更倾向于学习纹理特征而非形状特征(Shape Feature),且只有CNN具有较大的有效感受野(Effective Receptive Field, ERF)时,网络才倾向于学习形状特征。文献[20]中表明,ERF被视为从感受野(Receptive Field, RF)中央向边缘呈高斯分布(Gaussian Distribution)态势进行衰减的小范围高贡献感受区域(High-Contribution Receptive Field)。此外,研究还指出当模型具有与目标对象大小匹配的有效感受野时,它对形状特征的学习能力会显著提高,且被CNN模型学习到的形状特征对各种视觉变化具有健壮性。而广泛应用于步态识别领域的人体剪影轮廓(如图1所示),正是一种消除纹理特征之后仅包含形状特征的模态数据。另一方面,户外场景下获取的步态轮廓也具有更多样的视觉变化要素。基于此,本文从扩大模型的有效感受野并使它适配于行人目标区域的角度出发,探究构建更具判别性的针对现实户外场景的步态识别模型。




图1 户外场景下的跨视角步态序列

Fig. 1 Cross-view gait sequence in outdoor scene

具体地,本文从模型的整体架构和模块设计这2个方面构建一个更强大的步态识别模型,称为DilatedGait。在整体架构方面,构建一个以空洞卷积(Atrous Convolution, Dilated Convolution)(即扩张卷积)残差模块(Residual Block)^[21]为基础类ResNet作为特征提取器,对行人步态进行空间建模,以捕捉肢体局部变化和全局运动模式之间的潜在关联。相较于常规的残差卷积单元,残差空洞卷积块(Residual Atrous Convolution Block)能够进一步扩大模型的感受野,从而提高空间信息聚合能力,使模型更好地从步态轮廓中学习人体形状和行走模式特征。在模块设计方面,基于结构重参数化(Structural Reparameterization)和权重重参数化(Weight Reparameterization)思想^[22]提出扩张重参数化模块(Dilated Reparameterization Module, DRM)。该模块在捷径连接(Shortcut Connection)的基础上,通过融合多尺度卷积核的参数,成为具有不同感受野的隐式集成,进而优化了模型有效感受野的聚焦范围。同时,DRM也能从多尺度感受野中学习不同区域的步态表示之间的关系,从而提取丰富的全局上下文信息(Global Contextual Information)。

综上,本文的主要工作包括:

1) 构建一个基于空洞卷积的类ResNet架构步态模型,扩大了感受野范围并提高了空间聚合能力。

2) 提出扩张重参数化模块(DRM),通过重参数化方法融合多尺度卷积核参数进而优化模型的有效感受野范围,使它与识别对象区域更匹配,从而提高模型获得全局上下文信息的能力,有利于模型从步态轮廓提取更具判别性的空间特征。

3) 在Gait3D和GREW数据集上的实验结果表明,本文方法对现实户外场景下的步态识别具有更优越的性能。此外,消融实验分别验证了每部分的有效性。

1 基于重参数化和空洞卷积的步态识别

1.1 问题定义与整体流程

在本文中,步态识别被视为生物特征识别中的目标检索任务^[23]。给定行人步态数据,设 $S = \{s_i\}_{i=1}^N$ 为某个样本的步态轮廓序列, N 表示该轮廓序列的包含的帧数。在此假设下,本文通过特征处理和身份推理这2个阶段进行步态识别任务,具体表述如下。

在特征处理阶段,如图2所示,轮廓序列 S 被送入常规卷积进行特征映射,将原始轮廓转为拥有丰富结构特征(边缘、形状信息)的特征矩阵 $X \in \mathbb{R}^{N \times C \times H \times W}$,其中 C, H, W 分别表示通道数、高度和宽度。 X 会依次经过特征提取的3个步骤:首先,进入由残差空洞卷积块组成的浅层特征提取器,以获取细粒度的边缘局部特征。其次,经过 DRM 实现不同尺度信息的融合并提取多尺度运动特征,此时 DRM 会为模型构建更大的感受野并优化有效感受野对目标对象的聚焦范围。之后,进入同样由残差空洞卷积块构成的深层特征提取器,




图2 DilatedGait 整体网络框架

Fig. 2 Overall network framework of DilatedGait

1.2 特征处理

1.2.1 基于残差空洞卷积块的特征提取器

研究^[16]表明,已有的浅层步态模型在复杂户外场景的步态数据上表现不佳,而以 GaitBase 为首的更深架构的模型在户外场景下表现出对复杂协变量因素的更强健壮性。受该研究的启发,本文采用更深的网络结构提取特征,包括由5层残差模块组成的浅层特征提取器、1个用于扩大有效感受野的 DRM 和同样由5层残差模块组成的深层特征提取器。整个特征提取部分采用了广泛应用于图像识别任务的渐进式下采样策略。

此外,考虑轮廓图像在经过渐进式下采样的深度网络时它的空间分辨率会随着层数加深逐渐降低,使图像的空间结构难以被再分辨,进而导致细粒度要素模糊化,不利于模型对判别性语义特征的提取,本文使用空洞卷积替换残差模块中的常规卷积。一方面,空洞卷积在扩大神经元感受野的同时缓解了因下采样和模型变深引起的分辨率下降,有效提高了图像空间结构的辨识度;另一方面,空洞卷积不增加模型的复杂程度,使模型在保持原计算量的前提下加深对富含空间细节的轮廓模态的理解。并且,应用残差空洞卷积块的深度步态网络能够在反向传播(Back Propagation)的过程中学习并保存更多细微的空间信息,残差结构也能为模型在每一层卷积层中构建多尺度的感受野,有利于模型提取不同粒度的形状特征。

特征提取的具体流程如下。首先,轮廓序列 S 被送入卷积核尺寸为 3×3 的常规卷积(包括激活函数 ReLU

以从全局范围捕获粗粒度的运动模式特征。特征提取器将输出具有不同粒度特征且聚合更高维度空间语义信息的 $F_{Dilated}$ 经过特征提取后,为了获取序列中最具代表性的一帧, $F_{Dilated}$ 被送入时序池化(Temporal Pooling)层压缩帧级特征得到 F_{TP} 。最后, F_{TP} 被送入水平映射(Horizontal Mapping, HM)层^[10]进行水平分割,再通过联合池化操作得到 F_{HM} 。 F_{HM} 将在身份推理阶段用于目标检索。

在身份推理阶段,首先,使用分离式全连接层(Separate Fully Connected layer, SFC)将特征向量 F_{HM} 映射到样本度量空间,得到 $f_{Triplet}$ 作为三元组损失(Triplet Loss)函数 $L_{Triplet}$ 的输入;其次,将 $f_{Triplet}$ 送入由批归一化(Batch Normalization, BN)层和 SFC 共同组成的分离式批归一化瓶颈层(Separate Batch Normalization Neck layer, SBNNeck)^[24]并映射到身份判别空间得到 $f_{Cross-Entropy}$,作为交叉熵损失(Cross-Entropy Loss)函数 $L_{Cross-Entropy}$ 的输入;最后,使用不同权重2种损失函数构建联合损失函数 $L_{Combine}$ 。

(Rectified Linear Unit)^[25]和 BN 层)转化为特征矩阵 $X \in \mathbb{R}^{N \times C \times H \times W}$ 。其次,在浅层特征提取器中,卷积核尺寸为 3×3 ,膨胀率为2的一系列残差空洞卷积块构造了相对较小的感受野,以提取未经二次池化的 X 的边缘局部细节并加强局部区域的信息交互,如下所示:

$$X = \text{Act}(\text{BN}(\text{Conv}(S))) \quad (1)$$

$$X_1 = \text{DilatedResLayer}_1(X); X_1 \in \mathbb{R}^{N \times C \times H \times W} \quad (2)$$

$$X_{Dilated} = \text{DilatedResLayer}_2(X_1) \quad (3)$$

其中: $X_{Dilated} \in \mathbb{R}^{N \times 2C \times \frac{H}{2} \times \frac{W}{2}}$; $\text{Act}(\cdot)$ 代表激活函数; $\text{DilatedResLayer}_1(\cdot)$ 包含1个残差空洞卷积块; $\text{DilatedResLayer}_2(\cdot)$ 包含4个残差空洞卷积块,残差空洞卷积块由2个连续的膨胀率为2的 3×3 空洞卷积和1个 1×1 常规卷积组成。

再次,DRM 为模型构建更大的感受野并使有效感受野更多地聚焦目标对象区域,基于此,经过浅层特征提取的 $X_{Dilated}$ 再送入 DRM 后会获得丰富的全局上下文信息并融合更多尺度的肢体动作特征,如式(4)所示:

$$X_{DRM} = \text{DRM}(X_{Dilated}) \quad (4)$$

其中: $X_{DRM} \in \mathbb{R}^{N \times 2C \times \frac{H}{2} \times \frac{W}{2}}$; $\text{DRM}(\cdot)$ 代表 DRM 的整体操作(该部分将在 1.2.2 节详细说明)。

最后, X_{DRM} 会经过深层特征提取器进行二次池化,此时模型的感受野会超出整个特征图范围,有效感受野得以覆盖完整的行人目标区域,进而从全局范围捕获 X_{DRM} 的粗粒度

运动模式特征。经过深层特征提取后, X_{DRM} 将被转化为聚合高维空间语义的 F_{Dilated} , 表述如下:

$$F_1 = \text{DilatedResLayer}_3(X_{\text{DRM}}); F_1 \in \mathbf{R}^{N \times 4C \times \frac{H}{4} \times \frac{W}{4}} \quad (5)$$

$$F_{\text{Dilated}} = \text{DilatedResLayer}_4(F_1) \quad (6)$$

其中: $F_{\text{Dilated}} \in \mathbf{R}^{N \times 8C \times \frac{H}{4} \times \frac{W}{4}}$; $\text{DilatedResLayer}_3(\cdot)$ 包含 4 个残差空洞卷积块; $\text{DilatedResLayer}_4(\cdot)$ 包含 1 个残差空洞卷积块。

如图 3 所示, 特征处理流程如下。首先, 为了获取步态序列中最具判别性的富含人体形状信息的一帧, 使用最大池化(Max Pooling)操作对 F_{Dilated} 进行时间维度上的帧级压缩, 得到 F_{TP} , 如式(7)所示:

$$F_{\text{TP}} = \text{MaxPool}(F_{\text{Dilated}}) \quad (7)$$

其中 $F_{\text{TP}} \in \mathbf{R}^{1 \times 8C \times \frac{H}{4} \times \frac{W}{4}}$ 。

其次, 将 F_{TP} 送入 HM 层使用水平分割操作进行特征处理。具体地, 在水平方向上划分 F_{TP} , 获得共计 L 个部位的特征 $P \in \mathbf{R}^{8C \times L \times \frac{H}{4} \times \frac{W}{4}}$ 。在文献[10]中, HPM 层采用了多尺度划分方式对获得的所有部位特征池化后进行堆叠, 即令 $L = \sum_{k=1}^K 2^{k-1}$, 其中 K 为尺度数。而 GaitBase^[17] 的研究通过消融实验证明在移除 HPM 层的多尺度机制后, 模型不仅减少了 80% 的训练权重, 性能也有所提升, 因此本文选择使用 $L = 16$ 的单尺度 HM 层。最后, 对部位特征联合池化, 即全局平均池化(Global Average Pooling, GAP)和全局最大池化(Global Max Pooling, GMP), 获得处理后特征 $F_{\text{HM}} \in \mathbf{R}^{8C \times L \times 1}$, 具体表示为:

$$F_{\text{HM}} = \text{GAP}(P) + \text{GMP}(P) \quad (8)$$




图3 特征处理流程

Fig. 3 Flow of feature processing

1.2.2 扩张重参数化模块

为了构建与行人区域契合的有效感受野, 进而捕获轮廓剪影中更精细的形状特征和更健壮的步态运动模式, 本文从重参数化思想和模块架构出发构建扩张重参数化模块(DRM)。

参照结构重参数化和权重重参数化思想, DRM 通过重参数化模块(Reparameterization Module, RM)转换参数进而等效地转换模块结构。如图 4 所示, 首先将不同尺度的卷积核各自进行权重重参数化, 其次合并所有卷积核的参数进行结构重参数化。其中, 扩张卷积的核尺寸为 3×3 , 膨胀率为 2, 常规卷积包括一个核尺寸为 3×3 的卷积和一个核尺寸更大的卷积(这里为 5×5)。上述 3 种卷积均为分组数与通道数一致的深度可分离卷积(Depthwise Convolution)^[26], 旨在缓解复合卷积结构带来的更多参数与更大计算量的问题。

具体地, 首先, RM 采用 BN 操作对各个卷积核的参数分别进行批归一化处理, 以对每个卷积核进行权重重参数化。其次, RM 将不同尺度的卷积核参数相加进行参数融合(融合前均采用填充操作使所有核参数对应匹配), 从而实现结构重参数化。结构重参数使多种结构的卷积核参数相互关联, 编码来自不同卷积核的通道表征信息, 间接建立各个卷积核之间的跨通道关联, 以丰富模块结构的先验信息(Prior

Information)。同时, 融合了不同尺度卷积核参数的 RM 成为具有不同感受野的隐式集成, 进而优化了模型有效感受野对行人轮廓剪影的聚焦范围, 使模块能够提取更多尺度的动作特征与全局上下文信息。充足的上下文信息有助于消除局部线索歧义, 令模型提取出更具身份特点的鉴别性特征。此外, 应用填充操作后 RM 不仅加强了模型对局部特征之间的相对位置关系的学习, 也有助于编码绝对位置信息。




图4 重参数化模块

Fig. 4 Reparameterization module

在模块架构方面, 受 ViT(Vision Transformer)中多头自注意力(Multi-Head Self-Attention)机制优秀架构^[27-29] 的启发, 如图 2 所示, 本文在捷径连接的基础上, 使用深度可分离(Depthwise Separable)结构设计 DRM。具体地, DRM 在基于扩张卷积与常规卷积的重参数化部分前后, 使用核尺寸为 1×1 的权重重参数化卷积进行通道融合操作。基于深度可分离结构, DRM 中的扩张卷积的通道参数可以与常规卷积关联, 加强了跨通道的特征交互, 使空间特征表达更具健壮性。并且, DRM 在深度可分离结构之后串联了添加捷径连接的卷积式前馈神经网络(Convolutional Feed-Forward neural Network, ConvFFN)^[29]。ConvFFN 同样使用 1×1 的权重重参数化卷积, 以替代常规前馈神经网络(Feed-Forward neural Network, FFN)中的全连接网络(Fully Connected Network), 为模块提供更多非线性的信息传递。

DRM 的具体操作如下: 首先 X_{Dilated} 经过 BN 层进行特征归一化, 其次通过一个核尺寸为 1×1 的权重重参数化卷积扩张通道, 再次经过 BN 层和激活函数后, 特征向量 $X_{\text{Pre}} \in \mathbf{R}^{N \times 4C \times \frac{H}{2} \times \frac{W}{2}}$ 被送入 RM, 在更大的有效感受野上提取不同个体各自的协变量信息。输出的 $X_{\text{DilatedRep}} \in \mathbf{R}^{N \times 4C \times \frac{H}{2} \times \frac{W}{2}}$ 再次经过激活函数和权重重参数化卷积压缩通道, 并进行特征归一化, 得到包含更高维度语义特征的 $X_{\text{Rep}} \in \mathbf{R}^{N \times 2C \times \frac{H}{2} \times \frac{W}{2}}$ 。最后, 将重参数化后的 X_{Rep} 输入 ConvFFN 层, 获得 X_{DRM} 。过程表述如下:

$$X_{\text{Pre}} = \text{Act}(\text{BN}(\text{BNConv}(\text{BN}(X_{\text{Dilated}})))) \quad (9)$$

$$X_{\text{DilatedRep}} = \text{DilatedReparameterization}(X_{\text{Pre}}) \quad (10)$$

$$X_{\text{Rep}} = \text{BN}(\text{BNConv}(\text{Act}(X_{\text{DilatedRep}}))) + X_{\text{Dilated}} \quad (11)$$

$$X_{\text{DRM}} = \text{ConvFFN}(X_{\text{Rep}}) + X_{\text{Rep}} \quad (12)$$

其中: $\text{BNConv}(\cdot)$ 代表核尺寸为 1×1 的权重重参数化卷积; $\text{DilatedReparameterization}(\cdot)$ 代表应用扩张卷积和常规卷积的 RM 的重参数化操作; $X_{\text{DRM}} \in \mathbf{R}^{N \times 2C \times \frac{H}{2} \times \frac{W}{2}}$ 。式(9)~(12)也可表示为式(4)。

DRM 因重参数化具有更强的形状偏置(Shape Bias), 能够利用比常规卷积网络更多的形状信息, 有效避免了户外场景下的步态轮廓的特征丢失。

1.3 身份推理与损失函数

1.3.1 身份推理

在本阶段, 首先, 使用不共享权重且移除偏置项的 SFC 对水平特征向量 F_{HM} 中每个尺度的一维特征重映射到样本度量空间得到 f_{Triplet} , f_{Triplet} 作为三元组损失函数 L_{Triplet} 的输入

进行类间样本区分。相较于常规的全连接层映射,该操作使行人身体各部位之间的耦合弱化^[30],对更复杂的现实步态表征具有更强的健壮性。其次,将 f_{Triplet} 送入由BN层和SFC共同组成的SBNNeck并映射到身份判别空间得到 $f_{\text{Cross-Entropy}}$, $f_{\text{Cross-Entropy}}$ 作为交叉熵损失函数 $L_{\text{Cross-Entropy}}$ 的输入进行身份推理。最后,使用由不同权重的 L_{Triplet} 和 $L_{\text{Cross-Entropy}}$ 构建的联合损失函数 L_{Combine} 训练模型。SBNNeck能够有效减轻2个损失函数之间的耦合且保持同一个人特征的紧凑分布。

1.3.2 损失函数

模式识别领域中,损失函数常被用于衡量嵌入空间中各类样本的相似度差异。通过迭代训练,模型将逐步实现对相似样本在嵌入空间中的紧邻布局,同时将不相似的样本映射在较远的位置上。本文使用交叉熵损失函数 $L_{\text{Cross-Entropy}}$ 和三元组损失函数 L_{Triplet} 组成联合损失函数 L_{Combine} 。

交叉熵损失函数旨在最小化模型预测概率分布与真实标签分布之间的差异。该损失函数的定义如下:

$$L_{\text{Cross-Entropy}} = -\frac{1}{m} \sum_{i=1}^m \sum_{j=1}^n p(x_{ij}) \log(q(x_{ij})) \quad (13)$$

其中: m 为样本数; n 为行人类别总数; $p(x_{ij})$ 和 $q(x_{ij})$ 分别表示真实分布和预测分布中样本 i 为类别 j 的概率。

然而,由于步态识别中的类别数较多、类间差异较小等问题,交叉熵损失函数对维持特征空间中样本分布的紧凑性和区分性可能不如专门的度量学习损失函数。故步态识别研究常选用三元组损失函数^[31],以从步态序列中学习更具判别性的特征表示。三元组损失函数的核心思想是减小类内距离、增大类间距离以增强样本类别区分性,表示为:

$$L_{\text{Triplet}} = \max(d(f(a), f(r)) - d(f(a), f(u)) + \gamma, 0) \quad (14)$$

其中: a 代表锚点样本; r 为与锚点样本属于同一类别的正样本; u 是与锚点样本不同类别的负样本; $f(\cdot)$ 表示将样本映射到嵌入空间的函数; $d(z_1, z_2)$ 是嵌入空间中2个样本之间的欧氏距离; γ 代表正负样本之间期望的最小距离。

在受试人员非常多的户外场景下,每个人的训练样本数较少、类内距离与类间距离差距较小,单纯使用交叉熵损失将导致训练难以收敛,而三元组损失可以有效扩大类间距离并缩小类内距离,因此本文使用上述2种损失函数组成联合损失函数 L_{Combine} ,如式(15)所示:

$$L_{\text{Combine}} = \alpha L_{\text{Triplet}} + \beta L_{\text{Cross-Entropy}} \quad (15)$$

其中: α 和 β 作为超参数分别表示2种损失函数各自的权重,用以加速模型收敛并提高性能。

2 实验与结果分析

为了验证所提方法的有效性,在基于户外场景的公开步态数据集Gait3D^[5]和GREW^[32]上将DilatedGait与其他先进方法比较和评测。本文涉及的实验均在同一配置的实验环境下进行,以消除设备差异对实验结果产生的潜在影响。具体配置如下:CPU为Xeon Platinum 8352V处理器,GPU为NVIDIA GeForce RTX3090显卡,Python版本为3.8,CUDA版本为11.3,PyTorch版本为1.11.0。此外,本文还展示了不同模型的训练时间与有效感受野的可视化图像。

2.1 数据集介绍

Gait3D是杭州电子科技大学在一家大型超市收集的户外步态数据集。该数据集利用39台摄像机在不受约束的场景下采集了约1090 h的视频,视频分辨率为1920像素×1080像素,帧率为25 frame/s。Gait3D收集了4000名受试者

的步态信息,总计涵盖25309个步态表征序列。数据集提供多种数据表示以满足不同算法需求,包括三维人体网格、人体姿态关键点和轮廓剪影图像。本文遵循官方提供的数据集划分策略,选取前3000名行人作为训练集,其余1000名行人作为测试集。对于测试集,从每个行人步态数据中随机选出一个序列,构成包含1000个序列的探针集进行查询操作,剩余的5369个序列构成图库集。实验结果报告了多种评价指标,包括所有查询序列中Rank-1和Rank-5准确率,以及平均查准率均值(mean Average Precision, mAP)和平均逆负惩罚(mean Inverse Negative Penalty, mINP)^[33]。其中,Rank-1准确率因它的直观性和实用性,被作为主要评价指标衡量步态识别的效果。

GREW是清华大学在2021年发布的户外步态数据集。该数据集在开放环境下使用882台摄像机采集了26345名受试者的128671个步态序列。此外,GREW还包括一个由233857个序列组成的干扰集,更符合实际应用。GREW由3个部分组成:训练集包含20000名行人的102887个序列,验证集包含345名行人的1784个序列,测试集包含6000名行人的24000个序列。其中测试集的每名行人有4个步态序列,2个构成图库集,剩余2个用于查询。实验采用Rank准确率作为评价指标。

2.2 实验细节

训练阶段,采用预处理方法将人体轮廓对齐至图像中心区域,对于Gait3D,将图像裁剪至128×72尺寸;对于GREW,将图像裁剪至64×56尺寸。此外,为了增强模型对各类视觉变化的健壮性,对每个样本序列固定抽样30帧。测试阶段,直接输入原始尺寸的轮廓剪影,并使用所有帧测试。

本文的训练参数设置具体如下:在Gait3D上迭代训练 6×10^4 次,在GREW上迭代训练 1.8×10^5 次,每次迭代批次大小(Batch Size)为32×4;采用随机梯度下降(Stochastic Gradient Descent, SGD)优化器,初始学习率为0.1。为促进模型快速收敛并避免陷入局部最优解,设置动量(Momentum)为0.9;同时设置权重衰减系数为 5×10^{-4} ,旨在约束权重大小并避免梯度爆炸。三元组损失 L_{Triplet} 和交叉熵损失 $L_{\text{Cross-Entropy}}$ 的超参数系数 α 和 β 均为1.0,其中三元组损失的margin设置为0.2。为抑制实际场景中的噪声变化引起的模型过拟合,采用空间增强策略:随机透视(Random Perspective)概率、随机水平翻转(Random Horizontal Flip)概率和随机旋转(Random Rotate)概率,均设置为0.2。

2.3 与现有方法比较

在户外步态数据集Gait3D和GREW上进行实验,并将DilatedGait与其他先进方法比较,包括GaitSet^[10]、PoseGait^[3]、GaitPart^[11]、GaitGraph^[4]、GLN^[13]、GaitGL^[12]、CSTL^[6]、SMPLGait^[5]、GaitTAKE^[7]、GaitMix^[14]、GaitRef^[14]、GaitGCI^[9]、HSTL^[8]、TransGait^[15]和GaitBase^[17]。

如表1所示,在Gait3D数据集上,DilatedGait明显优于其他对比方法。具体地,DilatedGait在Rank准确率上获得显著提升。相较于首个基于该数据集的方法SMPLGait,本文方法的Rank-1和Rank-5分别提升了20.4和16.4个百分点;相较于先进方法GaitBase,本文方法也在Rank-1、Rank-5和mINP上获得了9.0、7.6和14.2个百分点的显著提升。与上述方法相比,DilatedGait的显著特点是充分利用了更深的扩张卷积架构为模型带来更大的有效感受野,使模型提取更充分的全局形状特征。另外,在mAP和mINP指标上分别达到

了 65.0% 和 45.6% 的先进水平也表明了 DilatedGait 在行人身份鉴别上具有更好的鲁棒性。Gait3D 作为基于户外场景的步态数据集,相较于过去基于实验室场景的数据集具有更多复杂的协变量因素,实验结果验证了 DilatedGait 消除了复杂协变量带来的不利影响,进一步提升了户外场景下步态识别的准确率。

表 1 在 Gait3D 数据集上不同方法的性能对比 单位:%
Tab. 1 Performance comparison of different methods on Gait3D dataset unit:%

方法	Rank-1	Rank-5	mAP	mINP
GaitPart ^[11]	29.9	50.6	23.3	13.2
GaitSet ^[10]	42.6	63.1	33.7	19.7
GLN ^[13]	42.2	64.5	33.1	19.6
CSTL ^[6]	12.2	21.7	6.4	3.3
GaitGL ^[12]	23.5	38.5	16.4	9.2
SMPLGait ^[5]	53.2	71.0	42.4	26.0
GaitTAKE ^[7]	53.1	71.9	43.3	27.1
GaitRef ^[14]	54.1	71.3	42.7	26.2
GaitGCI ^[9]	57.2	74.5	45.0	27.6
HSTL ^[8]	61.3	76.3	55.5	34.8
GaitBase ^[17]	64.6	79.8	53.4	31.4
DilatedGait	73.6	87.4	65.0	45.6

如表 2 所示,在 GREW 数据集上,DilatedGait 的检索性能同样优于其他对比方法。相较于 GaitBase,DilatedGait 在 Rank-1 和 Rank-5 指标上获得了 11.6 和 8.8 个百分点的提升。相较于 Gait3D 数据集,GREW 作为更大型的户外步态数据集,它收集的行人步态具有更大程度的视角变换和难以预料的遮挡现象。2 个数据集上的实验结果充分表明本文方法对于各种户外步态识别的复杂干扰具有良好的健壮性,体现了本文方法优越的检索性能。

表 2 在 GREW 数据集上不同方法的性能对比 单位:%
Tab. 2 Performance comparison of different methods on GREW dataset unit:%

方法	Rank-1	Rank-5	Rank-10	Rank-20
PoseGait ^[3]	0.2	1.1	2.2	4.3
GaitGraph ^[4]	1.3	3.5	5.1	7.5
GaitPart ^[11]	44.0	60.7	67.4	73.5
GaitSet ^[10]	46.3	63.6	70.3	76.8
CSTL ^[6]	50.6	65.9	71.9	76.9
GaitGL ^[12]	51.4	67.5	72.8	77.3
GaitTAKE ^[7]	51.3	69.4	75.5	80.4
GaitMix ^[14]	52.4	67.4	72.9	77.2
GaitRef ^[14]	53.0	67.9	73.0	77.5
TransGait ^[15]	56.3	72.7	78.1	82.5
GaitBase ^[17]	60.1	75.5	80.4	84.1
DilatedGait	71.7	84.3	88.1	90.8

2.4 消融实验

在 Gait3D 和 GREW 数据集上设计消融实验:在 Gait3D 上通过设计不同的重参数化方案,探究 DRM 的最优结构;在 Gait3D 和 GREW 数据集上将最优结构的 DRM 与空洞卷积结构组合,验证本文方法的有效性。

2.4.1 DRM 最优结构的探索

首先,为了验证 DRM 对户外步态识别的有效性,在 Gait3D 数据集上设计了多种重参数化方案的对比实验,探究

不同复合结构的 DRM 对识别准确率的影响,且将不使用空洞卷积和 DRM 的基线方法(Baseline)作为对照组。如表 3 所示,实验设置了共计 4 种方案,包括:①仅使用一个核尺寸为 3×3 的卷积对核尺寸为 3×3 、膨胀率为 2 的扩张卷积进行结构重参数化;②仅使用一个核尺寸为 5×5 的卷积对核尺寸为 3×3 、膨胀率为 2 的扩张卷积进行结构重参数化;③通过一个核尺寸为 3×3 和一个核尺寸为 7×7 的卷积对核尺寸为 3×3 、膨胀率为 3 的扩张卷积进行结构重参数化;④通过一个核尺寸为 3×3 和一个核尺寸为 5×5 的卷积对核尺寸为 3×3 、膨胀率为 2 的扩张卷积进行结构重参数化。上述所有方案均使用权重重参数化的深度可分离卷积,且核尺寸为 3×3 的卷积均进行外围填充以适应不同核尺寸参数。

表 3 DRM 的消融实验结果 单位:%
Tab. 3 Results of ablation experiments of DRM unit:%

编号	方案	Rank-1	Rank-5	mAP	mINP
	Baseline(对照组)	68.2	84.6	60.4	40.0
①	+扩张卷积(3×3 , $r=2$) +常规卷积(3×3)	69.8	84.8	62.0	41.5
②	+扩张卷积(3×3 , $r=2$) +常规卷积(5×5)	70.2	85.4	62.8	42.7
③	+扩张卷积(3×3 , $r=3$) +常规卷积(3×3) +常规卷积(7×7)	70.3	85.2	62.9	42.6
④	+扩张卷积(3×3 , $r=2$) +常规卷积(3×3) +常规卷积(5×5)	70.8	85.6	63.5	43.2

由实验结果可知,各个重参数化方案模型的各项准确率相较于基线方法均有所提升,使用 2 个不同尺度的卷积对扩张卷积进行重参数化的效果,从整体上看略优于仅使用单个尺度卷积的重参数化效果。其中,采用核尺寸为 3×3 和 5×5 这 2 种卷积对膨胀率为 2 的扩张卷积进行重参数化的方案④取得了最优的效果。这一结果表明通过不同尺寸卷积构建的多尺度感受野使模型学习了更多区域的步态表征,从而提取了更丰富的上下文信息。当扩张卷积的膨胀率大于 2 时,DRM 构造的 ERF 中的高贡献感受区域较分散,模型的效果略有下降;当膨胀率等于 2 时,高贡献感受区域相对集中,与行人目标范围更匹配,更有利于模型从步态剪影中提取更具判别性的全局空间特征。因此,本文采用方案④的策略对 DRM 进行重参数化,并基于此展开后续的消融实验。

2.4.2 空洞卷积架构与 DRM 组合的有效性验证

为了验证 DilatedGait 方法的有效性,在 Gait3D 和 GREW 数据集上设置了对比实验,将不使用空洞卷积和 DRM 的基线方法(Baseline)作为对照组,仅使用 DRM、仅使用残差空洞卷积块、使用残差空洞卷积块和 DRM 共 3 组方法作为实验组。

如表 4 所示,仅使用残差空洞卷积块构建特征提取器的方法相较于基线方法在识别准确率上提升更明显,其中在 GREW 数据集的 Rank-20 达到了 90.5%。这充分说明了空洞卷积使模型感受野进一步扩大,加强了模型对空间运动特征的聚合能力,也表明了在有更复杂协变量的户外步态数据集上,构建足够大的感受野对轮廓剪影模态的必要性。在同时使用残差空洞卷积与最优结构的 DRM 后(即 DilatedGait),模型准确率进一步提升,表明在空洞卷积构造的足够大感受野的基础上,DRM 能够调整 ERF 对行人的聚焦范围,使模型发掘更具健壮性及判别性的步态特征。上述实验结果表明了本文方法对提升步态识别性能的有效性。

表4 方法组合在Gait3D与GREW数据集上的准确率对比

单位: %

Tab. 4 Comparison of accuracy of method combinations on Gait3D and GREW datasets

unit: %

实验方法	Gait3D				GREW			
	Rank-1	Rank-5	mAP	mINP	Rank-1	Rank-5	Rank-10	Rank-20
Baseline(对照组)	68.2	84.6	60.4	40.0	68.6	82.0	86.1	88.2
+DRM	70.8	85.6	63.5	43.2	69.8	83.1	86.5	88.9
+残差空洞卷积块	72.7	87.2	64.7	45.2	71.0	84.1	87.8	90.5
DilatedGait	73.6	87.4	65.0	45.6	71.7	84.3	88.1	90.8

2.5 不同模型训练时间的对比

在Gait3D和GREW数据集上比较DilatedGait与其他先进方法的训练迭代次数与训练时长,各方法训练参数的设置均与各自论文的设置保持一致。如图5所示,在Gait3D数据集上,GaitGL、GaitPart和GaitSet在训练时迭代 1.8×10^5 次,GaitBase和DilatedGait迭代 6×10^4 次;在GREW数据集上,GaitGL、GaitPart和GaitSet迭代 2.5×10^5 次,GaitBase和DilatedGait迭代 1.8×10^5 次。在训练时长方面,本文的DilatedGait在Gait3D数据集上需训练约 4.7×10^4 s即可达到73.6%的Rank-1准确率,在GREW数据集上需训练约 9.6×10^4 s达到71.7%的Rank-1准确率。




图5 Gait3D和GREW数据集上不同模型训练时长的比较

Fig. 5 Comparison of training time of different models on Gait3D and GREW datasets

相较于其他方法,虽然DilatedGait因更深的网络架构与更多的模型参数花费了更多训练时间,但在不同数据集上明显优于其他方法的准确率,充分说明本文方法在户外步态识别方面的优越性。另外,更少的训练迭代次数也验证了DilatedGait在Gait3D和GREW数据集上具有更好的收敛性与特征学习能力。

2.6 不同模型有效感受野的可视化对比

通过获取各模型特征提取器(即时序池化层之前)的聚合贡献分数矩阵(Aggregated Contribution Score Matrix),并基于分数矩阵计算各贡献感受区域面积比,进而对有效感受野(ERF)进行可视化^[29]。高贡献感受区域(即深色区域)的面积越大,则代表模型的ERF范围越广,而更广的ERF范围有利于模型学习更多的全局形状特征。图6展示了GLN、GaitBase和DilatedGait的ERF可视化图像。




图6 不同模型有效感受野的可视化

Fig. 6 Visualization of different models' effective receptive fields

与GLN和GaitBase相比,DilatedGait构建的有效感受野范围更广,中等贡献区域完全覆盖了特征图范围,且保证高贡献区域聚焦在特征图中央。这验证了本文方法在扩大模型感受野和优化有效感受野对行人目标的聚焦区域这2个方面行之有效。

3 结语

本文提出一种基于空洞卷积和扩张重参数化的步态识别方法。采用的基于空洞卷积的特征提取器扩大了网络的感受野范围并提高它的空间聚合能力,扩张重参数化模块优化了有效感受野对目标的聚焦范围,使模型提取了更多尺度步态动作特征与全局上下文信息,进而获取更具身份特点的鉴别性特征。在户外步态数据集Gait3D和GREW的实验结果表明,本文方法对户外场景的步态识别准确率的提升显著,且对复杂的外观变化更具健壮性。但现阶段本文方法构建的有效感受野的聚焦区域尚未最大限度地匹配行人目标,仍需继续优化。未来将从可变形卷积出发,继续围绕构建更适配目标区域的有效感受野这一问题展开研究。

参考文献 (References)

- [1] 刘瑞华,郝子赫,邹洋杨. 基于多层级精细特征融合的步态识别算法[J]. 计算机应用, 2024, 44(7): 2250-2257. (LIU R H, HAO Z H, ZOU Y Y. Gait recognition algorithm based on multi-layer refined feature fusion[J]. Journal of Computer Applications, 2024, 44(7): 2250-2257.)
- [2] SHEN C, YU S, WANG J, et al. A comprehensive survey on deep gait recognition: algorithms, datasets and challenges [EB/OL]. [2024-04-03]. <https://arxiv.org/pdf/2206.13732>.
- [3] LIAO R, YU S, AN W, et al. A model-based gait recognition method with body pose and human prior knowledge [J]. Pattern Recognition, 2020, 98: No. 107069.
- [4] TEEPE T, KHAN A, GILG J, et al. GaitGraph: graph convolutional network for skeleton-based gait recognition [C]// Proceedings of the 2021 IEEE International Conference on Image Processing. Piscataway: IEEE, 2021: 2314-2318.
- [5] ZHENG J, LIU X, LIU W, et al. Gait recognition in the wild with dense 3D representations and a benchmark [C]// Proceedings of the 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2022: 20196-20205.
- [6] HUANG X, ZHU D, WANG H, et al. Context-sensitive temporal feature learning for gait recognition [C]// Proceedings of the 2021 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2021: 12889-12898.
- [7] HSU H M, WANG Y, YANG C Y, et al. GaitTAKE: gait recognition by temporal attention and keypoint-guided embedding [C]// Proceedings of the 2022 IEEE International Conference on Image Processing. Piscataway: IEEE, 2022: 2546-2550.
- [8] WANG L, LIU B, LIANG F, et al. Hierarchical spatio-temporal representation learning for gait recognition [C]// Proceedings of the 2023 IEEE/CVF International Conference on Computer Vision.

- Piscataway: IEEE, 2023: 19582-19592.
- [9] DOU H, ZHANG P, SU W, et al. GaitGCI: generative counterfactual intervention for gait recognition [C]// Proceedings of the 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2023: 5578-5588.
 - [10] CHAO H, WANG K, HE Y, et al. GaitSet: cross-view gait recognition through utilizing gait as a deep set [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(7): 3467-3478.
 - [11] FAN C, PENG Y, CAO C, et al. GaitPart: temporal part-based model for gait recognition [C]// Proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2020: 14213-14221.
 - [12] LIN B, ZHANG S, YU X. Gait recognition via effective global-local feature representation and local temporal aggregation [C]// Proceedings of the 2021 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2021: 14628-14636.
 - [13] HOU S, CAO C, LIU X, et al. Gait lateral network: learning discriminative and compact representations for gait recognition [C]// Proceedings of the 2020 European Conference on Computer Vision, LNCS 12354. Cham: Springer, 2020: 382-398.
 - [14] ZHU H, ZHENG W, ZHENG Z, et al. GaitRef: gait recognition with refined sequential skeletons [C]// Proceedings of the 2023 IEEE International Joint Conference on Biometrics. Piscataway: IEEE, 2023: 1-10.
 - [15] LI G, GUO L, ZHANG R, et al. TransGait: multimodal-based gait recognition with set transformer [J]. Applied Intelligence, 2023, 53(2): 1535-1547.
 - [16] FAN C, HOU S, HUANG Y, et al. Exploring deep models for practical gait recognition [EB/OL]. [2024-04-03]. <https://arxiv.org/pdf/2303.03301>.
 - [17] FAN C, LIANG J, SHEN C, et al. OpenGait: revisiting gait recognition toward better practicality [C]// Proceedings of the 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2023: 9707-9716.
 - [18] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition [C]// Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2016: 770-778.
 - [19] ZHANG Y, MAZUROWSKI M A. Convolutional neural networks rarely learn shape for semantic segmentation [J]. Pattern Recognition, 2024, 146: No. 110018.
 - [20] LUO W, LI Y, URTASUN R, et al. Understanding the effective receptive field in deep convolutional neural networks [C]// Proceedings of the 30th International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2016: 4905-4913.
 - [21] YU F, KOLTUN V, FUNKHOUSER T. Dilated residual networks [C]// Proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2017: 636-644.
 - [22] DING X, GUO Y, DING G, et al. ACNet: strengthening the kernel skeletons for powerful CNN via asymmetric convolution blocks [C]// Proceedings of the 2019 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2019: 1911-1920.
 - [23] 邓帆, 曾渊, 刘博文, 等. 基于Transformer时间特征聚合的步态识别模型 [J]. 计算机应用, 2023, 43(S1): 15-18. (DENG F, ZENG Y, LIU B W, et al. Gait recognition model based on temporal feature aggregation with Transformer [J]. Journal of Computer Applications, 2023, 43(S1): 15-18.)
 - [24] LUO H, GU Y, LIAO X, et al. Bag of tricks and a strong baseline for deep person re-identification [C]// Proceedings of the 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. Piscataway: IEEE, 2019: 1487-1495.
 - [25] GLOROT X, BORDES A, BENGIO Y. Deep sparse rectifier neural networks [C]// Proceedings of the 14th International Conference on Artificial Intelligence and Statistics. New York: JMLR.org, 2011: 315-323.
 - [26] CHOLLET F. Xception: deep learning with depthwise separable convolutions [C]// Proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2017: 1800-1807.
 - [27] LIU Z, LIN Y, CAO Y, et al. Swin Transformer: hierarchical vision Transformer using shifted windows [C]// Proceedings of the 2021 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2021: 9992-10002.
 - [28] DOSOVITSKIY A, BEYER L, KOLESHNIKOV A, et al. An image is worth 16x16 words: Transformers for image recognition at scale [EB/OL]. [2024-04-03]. <https://arxiv.org/pdf/2010.11929>.
 - [29] DING X, ZHANG X, HAN J, et al. Scaling up your kernels to 31x31: revisiting large kernel design in CNNs [C]// Proceedings of the 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2022: 11953-11965.
 - [30] 马玉祥, 代雪晶. 基于视频残差神经网络的深度步态识别 [J]. 计算机系统应用, 2024, 33(4): 279-287. (MA Y X, DAI X J. Deep gait recognition based on video residual neural network [J]. Computer Systems and Applications, 2024, 33(4): 279-287.)
 - [31] SCHROFF F, KALENICHENKO D, PHILBIN J. FaceNet: a unified embedding for face recognition and clustering [C]// Proceedings of the 2015 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2015: 815-823.
 - [32] ZHU Z, GUO X, YANG T, et al. Gait recognition in the wild: a benchmark [C]// Proceedings of the 2021 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2021: 14769-14779.
 - [33] YE M, SHEN J, LIN G, et al. Deep learning for person re-identification: a survey and outlook [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(6): 2872-2893.
- This work is partially supported by National Natural Science Foundation of China (61702158); Key Scientific Fund of Hebei Education Department (ZD2020317); Central Guidance on Local Science and Technology Development Fund (236Z0102G, 226Z1808G); Science and Technology Research Fund of Hebei Normal University (L2024ZD15, L2024J01, L2022B22).
- HUO Lina**, born in 1982, Ph. D., associate professor. Her research interests include computer vision, multi-modal learning, deep learning.
- XUE Leren**, born in 2002. His research interests include gait recognition, computer vision, deep learning.
- DAI Yujun**, born in 2003. His research interests include gait recognition, computer vision, deep learning.
- ZHAO Xinyu**, born in 2003. Her research interests include gait recognition, deep learning, computer vision.
- WANG Shihang**, born in 2004. His research interests include computer vision, gait recognition, deep learning.
- WANG Wei**, born in 1982, Ph. D., associate professor. His research interests include virtual reality, artificial intelligence.